

Tutorial 8: Cross-Validation y Selección de Variables

E337 – Introducción a Aprendizaje Automático para Economistas

Luciana Ramirez

Universidad de San Andrés – Otoño 2026

① Presentación teórica

- K-Fold Cross-Validation: repaso rápido
- Best Subset y Stepwise Selection: la idea
- Aplicaciones en economía: dos papers

② Práctica en Python

- Notebook de K-Fold CV
- Notebook de Best Subset y Stepwise Selection

K-Fold Cross-Validation: ¿Qué problema resuelve?

Problema: Queremos evaluar qué tan bien predice nuestro modelo *fuera de la muestra*.

- Si usamos **toda la muestra** para entrenar y evaluar $\Rightarrow$ sobreajuste (overfitting)
- Si hacemos **un solo split** train/test $\Rightarrow$ el resultado depende de qué observaciones cayeron en cada grupo

Solución: Repetir el split K veces y promediar.

En la práctica

`cross_val_score(model, X, y, cv=5)` en `sklearn` hace todo esto en una línea.

K-Fold CV: El procedimiento

- 1 Dividir los datos en K grupos ("folds") de tamaño similar
- 2 Para cada fold $k = 1, \dots, K$:
 - Entrenar el modelo con los otros $K - 1$ folds
 - Evaluar el error en el fold k (el que se dejó afuera)
- 3 El error de CV es el **promedio** de los K errores:

$$CV_{(K)} = \frac{1}{K} \sum_{k=1}^K MSE_k$$

Valores típicos: $K = 5$ o $K = 10$

Caso extremo: $K = n \Rightarrow$ Leave-One-Out CV (LOOCV)

- Menos sesgo, más varianza, muy costoso computacionalmente

CV: ¿Para qué lo usamos en la práctica?

- 1 Elegir entre modelos (ej: ¿grado 2 o grado 3 del polinomio?)
- 2 Elegir hiperparámetros (ej: el λ de LASSO/Ridge)
- 3 Elegir cuántas variables incluir (ej: en Best Subset)
- 4 Reportar una estimación honesta del error de predicción

Importante

CV no es un modelo. Es una **herramienta de evaluación** que se usa *dentro* de otros métodos para tomar decisiones.

El problema de selección de variables

Situación: Tenemos p predictores y queremos un modelo de regresión.

Pregunta: ¿Cuáles de los p predictores incluimos?

¿Por qué no incluir todos?

- Más variables $\Rightarrow$ más varianza en las estimaciones
- Overfitting: el modelo memoriza ruido
- Interpretabilidad: ¿cuáles importan realmente?

Tres estrategias clásicas:

- 1 Best Subset Selection
- 2 Forward Stepwise Selection
- 3 Backward Stepwise Selection

Best Subset Selection

Idea: Probar *todas* las combinaciones posibles de variables.

Algoritmo:

- ❶ Para cada $k = 0, 1, 2, \dots, p$:
 - Ajustar *todos* los modelos con exactamente k variables
 - Quedarse con el mejor (menor RSS) de ese tamaño $\Rightarrow \mathcal{M}_k$
- ❷ De $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$, elegir el mejor usando **CV**, C_p , BIC o R^2_{adj}

Ventaja:

- Garantiza encontrar el mejor modelo de cada tamaño

Problema:

- Son 2^p modelos en total
- $p = 20 \Rightarrow \sim 1$ millón de modelos
- Inviabile para $p > 30-40$

Forward Stepwise Selection

Idea: Empezar de cero e ir **agregando** variables de a una.

Algoritmo:

- ① Empezar con $\mathcal{M}_0$ (solo el intercepto)
- ② Para $k = 0, 1, \dots, p - 1$:
 - De las variables que **no están** en el modelo, agregar la que más reduce el RSS
 - Esto genera $\mathcal{M}_{k+1}$
- ③ Elegir entre $\mathcal{M}_0, \dots, \mathcal{M}_p$ usando **CV**, C_p , BIC o R_{adj}^2

Costo computacional: $1 + p + (p - 1) + \dots + 1 = 1 + p(p + 1)/2$ modelos

$\Rightarrow$ Con $p = 20$: solo 211 modelos (vs. 1,048,576 de Best Subset)

Trade-off

Es mucho más rápido, pero **no garantiza** encontrar el mejor modelo global (es un algoritmo *greedy*).

Backward Stepwise Selection

Idea: Empezar con todo e ir **sacando** variables de a una.

Algoritmo:

- ① Empezar con $\mathcal{M}_p$ (todas las variables)
- ② Para $k = p, p-1, \dots, 1$:
 - Sacar la variable que **menos aporta** (menor impacto en RSS)
 - Esto genera $\mathcal{M}_{k-1}$
- ③ Elegir entre $\mathcal{M}_0, \dots, \mathcal{M}_p$ usando **CV**, C_p , BIC o R_{adj}^2

Limitación: Requiere $n > p$ (necesita poder ajustar el modelo completo)

Resumen comparativo

	Best Subset	Forward	Backward
Modelos evaluados	2^p	$\sim p^2/2$	$\sim p^2/2$
Óptimo global?	Sí	No	No
Funciona si $p > n$?	No	Sí	No

Conexión clave: CV + Selección de variables

CV es el método preferido para elegir el tamaño del modelo en cualquiera de los tres procedimientos.

El flujo en la práctica:

- 1 Best Subset / Forward / Backward genera $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$
- 2 Para cada $\mathcal{M}_k$, computar el error de CV
- 3 Elegir el k^* que minimiza el error de CV
- 4 Reajustar $\mathcal{M}_{k^*}$ con **toda** la muestra

Anticipando lo que viene (Clases 9 y 10)

Best Subset/Stepwise: variable está **adentro o afuera** (discreto)

LASSO: **achica** coeficientes continuamente y algunos van a cero $\Rightarrow$ selección automática

Aplicaciones en Economía

¿Cómo usan los economistas estas herramientas?

“A Note on the Statistical Significance of Changes in Inequality”

Económica, Vol. XLVI.

Contexto:

- El Gini de GBA subió de 0.443 a 0.457 entre 1993 y 1994
- ¿Es un cambio **real** en la desigualdad, o es **ruido muestral**?
- La EPH encuesta hogares distintos cada onda $\Rightarrow$ variabilidad muestral

Problema práctico:

- Calcular la varianza analítica del Gini es muy complejo
- Fórmulas asintóticas pueden no funcionar bien en muestras finitas

Solución: Usar **bootstrap** (el primo de CV en la familia de remuestreo)

Paper 1: ¿Qué es el bootstrap?

Idea: Simular “nuevas muestras” remuestreando *con reemplazo* de la muestra original.

Procedimiento:

- 1 Tomar una muestra con reemplazo de tamaño N de los datos originales
- 2 Calcular el estadístico de interés (ej: coeficiente de Gini)
- 3 Repetir B veces (ej: $B = 300$ o $B = 1000$)
- 4 Usar las B estimaciones para calcular desvío estándar e IC

Conexión con CV

- **CV** remuestrea para estimar el *error de predicción* de un modelo
- **Bootstrap** remuestrea para estimar la *variabilidad* de un estadístico
- Ambos son **métodos de remuestreo** (ISLP Cap. 5)

Paper 1: Resultados con la EPH

Datos: EPH, Gran Buenos Aires y Neuquén, 1992–1997.

Región	Año	Gini	SE (bootstrap)	Coef. Var.
GBA	1992	0.4415	0.0072	1.6%
GBA	1994	0.4570	0.0077	1.7%
GBA	1997	0.4797	0.0074	1.6%
Neuquén	1992	0.4632	0.0113	2.4%
Neuquén	1997	0.4718	0.0137	2.9%

Hallazgo clave:

- GBA ($n \approx 3,400$ hogares): cambios entre años consecutivos **no** son estadísticamente significativos en la mayoría de los casos
- Neuquén ($n \approx 748$): **casi ningún** cambio es significativo
- Solo cambios entre años *distantes* (ej: 1992 vs. 1997) son significativos

Mensaje para la práctica

Sin remuestreo, no sabemos si lo que vemos es señal o ruido.

Implicancias para política pública:

- Reportar que “el Gini subió de 0.443 a 0.457” sin un IC es **incompleto**
- Con muestras chicas (ej: provincias), la mayoría de los cambios observados pueden ser ruido muestral
- El bootstrap permite cuantificar esta incertidumbre de forma simple

Relevancia metodológica:

- El bootstrap no requiere supuestos distribucionales fuertes
- Funciona para *cualquier* medida de desigualdad
- Es computacionalmente barato

“High-Dimensional Methods and Inference on Structural and Treatment Effects”

Journal of Economic Perspectives, 28(2), 29–50.

Problema: En economía aplicada, frecuentemente tenemos **muchas variables de control** posibles (p grande, a veces $p > n$).

Ejemplos del paper:

- Efecto de *eminent domain* sobre precios de vivienda: 147 instrumentos potenciales, $n = 183$
- Efecto del aborto sobre el crimen: 284 controles, $n = 600$
- Efecto de instituciones sobre producto: 12 controles geográficos, $n = 64$

¿Por qué no incluir todo? $\Rightarrow$ Cuando $p \approx n$ o $p > n$, OLS no funciona (overfitting, $R^2 = 1$, predicciones inútiles fuera de muestra).

Paper 2: ¿Por qué no alcanza con Best Subset?

Con $p = 284$ **variables** (ejemplo aborto/crimen):

- Best Subset requeriría evaluar 2^{284} modelos $\approx 3 \times 10^{85}$
- Forward/Backward: $\sim 40,000$ modelos (factible, pero...)

El problema más profundo: Selección de variables para **predicción** $\neq$ selección para inferencia causal

- LASSO/Stepwise optimizan **predicción** de Y
- Pero pueden **omitir** variables correlacionadas con el tratamiento
- Esto genera sesgo por **variables omitidas** en la estimación de efectos causales

Solución: "Double Selection"

Usar LASSO dos veces: una para predecir Y y otra para predecir D (tratamiento). Incluir la **unión** de las variables seleccionadas como controles.

Paper 2: Ejemplo – Efecto del aborto sobre el crimen

Estimador	Tipo de crimen		
	Violento	Propiedad	Homicidio
Controles originales (few)	-0.157 (0.034)	-0.106 (0.021)	-0.218 (0.068)
Todos los controles (284)	0.071 (0.284)	-0.161 (0.106)	-1.327 (0.932)
Double Selection (LASSO)	-0.171 (0.117)	-0.061 (0.057)	-0.189 (0.177)

Lectura:

- **Few controls:** resultados significativos, pero ¿omite confounders?
- **All controls:** estimaciones imprecisas e inestables ($p \approx n$)
- **Double Selection:** LASSO elige qué controles importan $\Rightarrow$ estimaciones sensatas con ICs razonables

Mensaje

La selección de variables no es solo una técnica de machine learning: es una herramienta para hacer **mejor economía aplicada**.

¿Qué rol juega CV acá?

- CV se usa para elegir el λ de LASSO (el parámetro de penalización)
- λ controla cuántas variables se seleccionan
- **Sin CV**, no hay forma principitada de elegir λ

Hilo conductor de la clase:

- 1 CV $\Rightarrow$ herramienta para evaluar y elegir
- 2 Best/Stepwise $\Rightarrow$ primer intento de selección (discreto, limitado)
- 3 LASSO $\Rightarrow$ selección moderna (continuo, escalable) – Clases 9 y 10

Lo que vimos:

- K-Fold CV: evaluar modelos fuera de muestra
- Best Subset: probar todas las combinaciones
- Stepwise: agregar/sacar variables de a una
- Bootstrap para inferencia (Sosa Escudero & Gasparini)
- Selección de variables en economía causal (Belloni et al.)

Lo que vamos a hacer ahora:

- Tut7_CV.ipynb: K-Fold CV en Python con dataset Auto
- Tut8_Best_Stepwise.ipynb: Best Subset y Stepwise con dataset Hitters

Lecturas:

- ISLP Cap. 5 (CV)
- ISLP Cap. 6.1 (Selección)
- Sosa Escudero, *Big data* Cap. 5

- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *Journal of Economic Perspectives*, 28(2), 29–50.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning: With Applications in Python*. Springer. Cap. 5 y 6.
- Sosa Escudero, W. (2021). *Big data*. 7a ed., Siglo XXI. Cap. 5.
- Sosa Escudero, W., & Gasparini, L. (2000). A Note on the Statistical Significance of Changes in Inequality. *Económica*, XLVI.