

Machine learning y políticas públicas:

Detección temprana de violencia infantil

Edo, M. Oubiña, V. Svarc, M.

Presentado por:

Gomez Kum Denise López María Justina Ramirez Luciana Azul

Big Data
Universidad de San Andrés

2025

1. Introducción
2. Datos y metodología
3. Resultados
4. Conclusiones
5. Apéndice

Introducción

- **Violencia infantil:** incluye abuso, negligencia y castigo corporal.
 - A nivel mundial solo **1/75 casos** se denuncia.
 - En Argentina, **59,4 %** de niños sufre violencia disciplinaria.
 - En Buenos Aires, **27.000 casos vs. 11.774 intervenciones.**
- Modelos de **ML predicen riesgo** de violencia infantil.
- **Objetivo:** detección temprana, apoyo a profesionales.
- **Resultado:** **43 % de casos** detectados en el **30 % más riesgoso.**

Evaluación de riesgos en la protección infantil

- **Evaluación tradicional:** Modelos teóricos (subjetivos) o Modelos actuariales (rígidos).
- **Modelo de Predicción de Riesgos (MPR):** usa análisis predictivo para detectar patrones ocultos y tendencias emergentes.
- Requiere **muchos datos, actualización constante y protocolos éticos y legales claros.**
- Casos exitosos: **Nueva Zelanda, Chile, EE.UU.**
- En Argentina: modelo OIT–CEPAL sobre riesgo de trabajo infantil.

Datos y metodología

- **Encuesta de Indicadores Múltiples por Conglomerados (MICS)-UNICEF 2019-20.**
 - 4 Cuestionarios:
 1. Hogares
 2. Mujeres (15 a 49 años)
 3. Niños (menores de 5 años)
 4. Niños y adolescentes (5 a 17 años)
 - $n = 7.358$ hogares (1 a 14 años)
- Pregunta: **métodos disciplinarios del hogar en el último mes.**
- Controles: indicadores socioeconómicos, condiciones laborales, cobertura sanitaria y de salud, desarrollo infantil, etc.
- Problemas: subdeclaración.

- Dos enfoques:
 - **Random Forest** (flexibilidad, modelo de caja negra, captura no linealidades)
 - **LASSO-Logit** (interpretabilidad, linealidad asumida, menos flexible).
- $p = P(Y = 1 \mid X = x)$ = Probabilidad de violencia infantil en un hogar.
- 70 % entrenamiento, 30 % validación.
- Validación cruzada k-veces para selección de hiperparámetros.
 - **Random Forest:** $k = 5$; parámetro = regresores en cada partición de cada árbol.
 - **Lasso-Logit:** $k = 10$; parámetro = λ .

Métricas para evaluar el rendimiento del modelo

Cuadro: Matriz de confusión.

Clase Real	Clase Predicha		Total
	Negativa (sin violencia)	Positiva (violencia)	
Negativa (sin violencia)	Verdadero Negativo (TN)	Falso Positivo (FP)	N
Positiva (violencia)	Falso Negativo (FN)	Verdadero Positivo (TP)	P
Total	N^*	P^*	

- **Sensibilidad** = $TP / (TP + FN) = TP / P$
- **Especificidad** = $TN / (TN + FP) = TN / N$
- **Precisión positiva:** $VPP = TP / (TP + FP) = TP / P^*$
- **Precisión negativa:** $VPN = TN / (TN + FN) = TN / N^*$

Selección del umbral

- *Random forest* y *Lasso-logit* asignan puntajes entre 0 y 1 según el riesgo de violencia.
- La clasificación depende de un **umbral** que determina hogares violentos.
- El **umbral óptimo** se elige con el **índice de Youden**:

$$J = \text{sensibilidad} + \text{especificidad} - 1$$

Umbral más bajo $\longrightarrow \uparrow$ Sensibilidad, $\downarrow$ Especificidad

- Limitación operativa $\longrightarrow$ criterio del alcance máximo de hogares.

Resultados

Estadística descriptiva I

- El 41.8 % de los hogares declara haber utilizado al menos un método de castigo físico.
- Hay una baja correlación entre los distintos métodos.




Figura: Prevalencia del castigo físico, por método usado. Fuente: Elaboración propia en base a la encuesta MICS Argentina (2019-20)

- La prevalencia de castigo físico es mayor en el quintil más pobre y menor en el más rico.




Figura: Prevalencia del castigo físico, por quintiles de riqueza. Fuente: Elaboración propia en base a la encuesta MICS Argentina (2019-20)

Resultados del modelo

- Se estimaron dos modelos: **Random Forest** y **Lasso-Logit**.
- La clasificación del **Panel A**, es en base al índice de Youden.
- El **Panel B** tiene indicadores de desempeño.
- Realizan análisis de sensibilidad con cambios en el umbral: no hay cambios en la precisión pero si en la sensibilidad y en la especificidad.

Cuadro: Desempeño de modelos Random Forest y Lasso-logit

	Random Forest	Lasso-logit
<i>Panel A: predicción y umbrales (%)</i>		
Umbral	48	40.1
P*/Total	36	48
<i>Panel B: desempeño predictivo (%)</i>		
Exactitud (Accuracy)	63	63
Sensibilidad (Sensitivity)	49	63
Especificidad (Specificity)	74	63
Precisión positiva (PPV)	59	57
Precisión negativa (NPV)	66	69

Nota: P*/Total es la proporción de casos positivos predichos sobre el total de observaciones en la muestra de entrenamiento.

- **Random Forest:**

- 55 variables.
- Las más relevantes: **infraestructura, educación, salud, demografía.**

- **Lasso-Logit:**

- Usa 27 % de variables → penaliza coeficientes.
- Factores similares: **hogar, educación, salud, adolescentes.**

- Ambos confirman: los **determinantes estructurales del hogar** influyen directamente en el riesgo de violencia infantil

Se evaluó el desempeño de ambos modelos por quintil de ingresos.

Principales hallazgos:

- El modelo Lasso-Logit muestra **mayor sensibilidad en hogares pobres** y menor en los más ricos.
- El Random Forest mantiene resultados más estables entre quintiles, aunque también tiende a predecir mejor en contextos de mayor vulnerabilidad.

El paper sugiere ajustar umbrales según quintil para equilibrar sensibilidad y precisión, priorizando la detección en los grupos más vulnerables.

Se restringe la variable dependiente a **castigos físicos severos**

Resultados principales:

- Ambos modelos mantienen precisión y especificidad similares.
- **Random Forest** logra mayor sensibilidad al identificar hogares donde se ejerce violencia severa.

Implicancias:

- Algoritmos no solo detectan la presencia de violencia física, sino que también distinguen niveles de severidad.
- Permite priorizar intervenciones más urgentes y ajustar estrategias de prevención.

Conclusión

- La **violencia infantil** persiste con altos niveles de **subregistro**.
- El uso de **machine learning** muestra **viabilidad** para detección temprana.
- **Lasso-logit** y **Random Forest**: identifican el 43 % de los casos en el 30 % de mayor riesgo.
- Supone una **mejora frente al status quo**: más eficiencia y cobertura.
- Requiere una **implementación ética y cuidadosa**: evitar sesgos y proteger la privacidad.
- Debe **complementarse con datos administrativos** y mirada profesional.
- Futuros pasos: **mayor precisión** y un mejor **sistema nacional de alerta temprana**.

Muchas gracias :)

- Cambios en los umbrales.
- Umbral: entorno índice de Youden.
- Recordar: + alto, – estigmatización pero – detección.

Performance of the lasso-logit classifier for different thresholds.

<i>Panel A: prediction and thresholds (%)</i>					
Threshold	35 %	40.1 %	45 %	50 %	55 %
P*/Total	65	48	32	22	15
<i>Panel B: prediction performance (%)</i>					
Accuracy	60	63	64	63	62
Sensitivity	79	63	45	33	23
Specificity	46	63	78	86	91
Positive Precision (PPV)	53	57	60	65	66
Negative Precision (NPV)	75	69	65	63	61

Source: own elaboration based on MICS survey of Argentina (2019–20).

Figura: Lasso-Logit

Performance of the random forest model for different thresholds.

<i>Panel A: prediction and thresholds (%)</i>					
Threshold	40 %	45 %	48 %	50 %	55 %
P*/total	57	43	36	28	18
<i>Panel B: prediction performance (%)</i>					
Accuracy	60	62	63	63	63
Sensitivity	70	56	49	40	27
Specificity	53	67	74	81	89
Positive Precision (PPV)	53	56	59	61	66
Negative Precision (NPV)	70	67	66	64	62

Source: own elaboration based on MICS survey of Argentina (2019–20).

Figura: Random Forest