

Regularización: LASSO, Ridge y Elastic Net

Tutorial 9 – Aplicaciones

Luciana Azul Ramirez

E337 – Big Data para Economistas
Universidad de San Andrés

Otoño 2026

Primera parte: papers aplicados

- 1 Repaso rápido: **LASSO**, **Ridge** y **Elastic Net**.
- 2 **Edo, Oubiña & Svarc (2024)** – LASSO-logit para detección temprana de violencia infantil.
- 3 **Bajari, Nekipelov, Ryan & Yang (2015)** – Comparación de métodos de ML para estimar demanda.
- 4 **Zou & Hastie (2005)** – El paper fundacional del Elastic Net.

Segunda parte: código en Python

Recorrida del notebook `Tut9_Regularizacion.ipynb`: `scikit-learn`, Lasso, Ridge, ElasticNet y selección de λ con validación cruzada.

Repaso teórico

LASSO, Ridge y Elastic Net en una slide

¿Por qué regularizar?

- Cuando hay **muchos predictores** (p grande) o **multicolinealidad**, OLS:
 - tiene varianza alta (overfitting),
 - es poco interpretable,
 - no está definido si $p > n$.
- **Idea**: agregar una penalidad sobre β que reduzca varianza a cambio de un poco de sesgo.
- Las tres alternativas estándar:

Mismo problema, distinta penalidad

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2}_{\text{ajuste}} + \underbrace{\lambda \cdot P(\beta)}_{\text{penalidad}}$$

Las tres penalidades

Ridge

$$P(\beta) = \sum_{j=1}^p \beta_j^2$$

- Penalidad L_2 .
- Encoge coeficientes hacia 0 pero **nunca** los hace exactamente 0.
- Maneja bien la **multicolinealidad**.
- No hace selección de variables.

LASSO

$$P(\beta) = \sum_{j=1}^p |\beta_j|$$

- Penalidad L_1 .
- Encoge y fija coeficientes en 0 $\Rightarrow$ selección automática.
- Modelo **parsimonioso**.
- Falla con grupos de variables correlacionadas (elige una al azar).

Elastic Net

$$P(\beta) = \alpha \sum |\beta_j| + (1 - \alpha) \sum \beta_j^2$$

- Combinación convexa de L_1 y L_2 .
- Selección y efecto **de agrupamiento**.
- Bien definido cuando $p > n$.
- Dos hiperparámetros: λ y α .

Hoy: vamos a ver un paper aplicado de cada uno.

Primer Trabajo

Edo, Oubiña & Svarc (2024)

Machine learning and public policy: Early detection of physical violence against children

Children and Youth Services Review, 166, 107932.

- **Problema:** la violencia física contra niños está muy subreportada.
 - Mundo: solo **1 de cada 75** casos de abuso físico se denuncia.
 - Argentina (MICS 2019-20): **59,4 %** de los menores de 15 sufren violencia disciplinaria; **35,4 %**, castigo corporal.
- **Pregunta:** ¿se puede usar machine learning para identificar tempranamente hogares en riesgo?
- **Por qué importa para nuestro tema:** muchas variables disponibles (643) y necesidad de un modelo interpretable $\Rightarrow$ caso típico para **LASSO**.

- Encuesta de Indicadores Múltiples por Conglomerados (MICS) de UNICEF.
- 4 cuestionarios: hogares, mujeres (15-49), niños <5, niños 5-17.
- Muestra utilizada: **n = 7.358 hogares** con niños de 1 a 14 años.
- **Variable Y**: dummy que vale 1 si en el último mes algún adulto del hogar usó algún método de castigo físico contra el niño/a.
- **Variables X**: **643 variables** (después de one-hot encoding) sobre características socioeconómicas, laborales, sanitarias, de vivienda y desarrollo infantil.
- Imputación por mediana condicional dentro del quintil de riqueza.

Dos modelos comparados:

- **Random Forest** – modelo de caja negra, captura no linealidades.
- **LASSO-logit** – regresión logística penalizada:

$$\hat{\beta} = \arg \min_{\beta} -\ell(\beta) + \lambda \sum_{j=1}^p |\beta_j|$$

donde $\ell(\beta)$ es la log-verosimilitud logística.

Implementación

- Split: **70 % training / 30 % validación**.
- Selección de λ por **cross-validation** $k = 10$; se elige λ dentro de *una desviación estándar* del óptimo (regla *1-SE*).
- Software: R.

Evaluación: matriz de confusión

Clase real	Clase predicha		Total
	Negativo (sin violencia)	Positivo (violencia)	
Negativo	TN	FP	N
Positivo	FN	TP	P
Total	N^*	P^*	

- Sensibilidad = TP/P Especificidad = TN/N
- Precisión positiva (PPV) = TP/P^* Precisión negativa (NPV) = TN/N^*
- **Umbral óptimo:** índice de Youden $J = \text{Sens.} + \text{Espec.} - 1$.
- Alternativa operativa: *maximum household reach* (ordenar por score y cubrir el 30 % top).

Resultados principales (Tabla 2 del paper)

	Random Forest	LASSO-logit
Umbral	0,48	0,401
P^*/Total	36 %	48 %
Accuracy	63 %	63 %
Sensibilidad	49 %	63 %
Especificidad	74 %	63 %
Precisión positiva (PPV)	59 %	57 %
Precisión negativa (NPV)	66 %	69 %

- **LASSO-logit** detecta más casos verdaderos de violencia (mayor sensibilidad).
- **Random Forest** se equivoca menos en hogares sin violencia (mayor especificidad).

¿Qué hace el LASSO acá?

- De **643 variables** iniciales, el LASSO-logit **conserva alrededor del 27 %** (las demás reciben coeficiente 0).
- Variables más relevantes: educación del jefe de hogar, salud, infraestructura, características demográficas, presencia de adolescentes.
- Coincide con las variables que Random Forest también identifica como importantes.
- **Mensaje clave:** el LASSO logra un modelo **interpretable** sin perder precisión predictiva frente al RF.

Resultado de política

Atendiendo al **30 % de hogares con mayor score**, el modelo logra identificar a **43 de cada 100** hogares donde efectivamente hay violencia.

- Subregistro: si ciertos grupos reportan menos, las predicciones también sub-estiman su riesgo.
- No reemplaza al trabajador social $\Rightarrow$ es una herramienta de *screening* temprano.
- Requiere datos administrativos integrados y un protocolo ético/legal claro.
- LASSO-logit es heterogéneo entre quintiles de ingreso: mayor sensibilidad en hogares pobres.
- Casos similares en el mundo: Allegheny Family Screening Tool (EE.UU.), Sistema Alerta Niñez (Chile), Nueva Zelanda.

Segundo Trabajo

Bajari, Nekipelov, Ryan & Yang (2015)

Machine Learning Methods for Demand Estimation

American Economic Review: Papers & Proceedings, 105(5), 481-485.

- **Pregunta aplicada:** ¿pueden los métodos de ML mejorar la estimación de **demanda** respecto de los modelos econométricos estándar (regresión lineal y logit)?
- Hace una década había **poca difusión** de estas técnicas en economía aplicada; el paper las introduce en un caso canónico.
- **Por qué importa para nuestro tema:** muestra cómo **LASSO** y otros métodos predictivos rinden frente a OLS *con muchos regresores y multicolinealidad*.

- Datos de **IRI Marketing Research** (Universidad de Chicago, licencia académica).
- Categoría: **snacks salados** de una cadena de supermercados, 6 años de datos.
- Unidad de observación: producto j (definido por UPC) en tienda m en semana t .
- $n = 1,510,563$ **observaciones**, 3,149 **productos únicos**.
- Variable dependiente: $\log(\text{unidades vendidas por semana})$.
- Predictores: $\log(\text{precio})$, atributos del producto (marca, sabor, tamaño, grasa, sal. . .), promociones, fixed effects de tienda y semana.
- Con fixed effects de producto y tienda hay **miles** de regresores $\Rightarrow$ selección de variables es clave.

Econométricos clásicos

- Regresión lineal (OLS)
- Logit

Métodos de selección

- Stepwise regression
- Forward stagewise
- **LASSO**

Métodos basados en árboles

- Bagging
- Random Forest

Otros

- Support Vector Machine (SVM)
- **Combined model** (combinación lineal de los 8)

Diseño

Split en **3 conjuntos**: 60 % training (estima cada modelo), 15 % validation (estima pesos del modelo combinado), 25 % holdout (mide RMSE out-of-sample).

Método	Validación		Out-of-sample	
	RMSE	SE	RMSE	SE
Lineal	1,169	0,022	1,193	0,020
Stepwise	0,983	0,012	1,004	0,011
Forward stagewise	0,988	0,013	1,003	0,012
LASSO	1,178	0,017	1,222	0,012
Random forest	0,943	0,017	0,965	0,015
SVM	1,046	0,024	1,068	0,018
Bagging	1,355	0,030	1,321	0,025
Logit	1,190	0,020	1,234	0,018
Combined	0,924	—	0,946	—

Pesos del *combined model*: Random Forest 65,6 % · SVM 15,7 % · Stepwise 12,1 % · Lineal 6,6 %.

¿Qué aprendemos?

- Los métodos de ML **en general** predicen mejor fuera de muestra que OLS o logit.
- Pero **ningún método domina a todos**: acá **Random Forest** es el mejor individual; LASSO *no* brilla en este dataset.
- ¿Por qué LASSO no gana acá? La relación demanda-precio es muy no lineal y RF la captura mejor.
- **Combinar modelos** con pesos por regresión lineal mejora el RMSE incluso del mejor método individual (*Bates & Granger, 1969*).

Reflexión

Las herramientas de ML son **accesibles** (R, Python), **escalables** y **flexibles**. No reemplazan la teoría económica, la **complementan** para predicción.

Tercer Trabajo

Zou & Hastie (2005)

Regularization and variable selection via the elastic net

Journal of the Royal Statistical Society B, 67(2), 301-320.

¿Por qué un método nuevo? Tres limitaciones del LASSO

- ❶ **Cuando $p > n$:** el LASSO selecciona **como máximo n variables** (queda saturado).
 - Crítico en microarrays (miles de genes, decenas de muestras).
- ❷ **Grupos de variables correlacionadas:** el LASSO tiende a seleccionar **una sola al azar** y descartar las demás.
 - Pierde información del grupo completo.
- ❸ **Cuando $n > p$ con alta correlación:** empíricamente, **Ridge predice mejor** que LASSO (Tibshirani, 1996).

Idea

Construir un método que **combine lo mejor de Ridge y LASSO**.

Naïve elastic net:

$$\hat{\beta} = \arg \min_{\beta} |y - X\beta|^2 + \lambda_2 |\beta|^2 + \lambda_1 |\beta|_1$$

Re-parametrizando con $\alpha = \lambda_2/(\lambda_1 + \lambda_2)$:

$$\hat{\beta} = \arg \min_{\beta} |y - X\beta|^2 \quad \text{s.a.} \quad (1 - \alpha) |\beta|_1 + \alpha |\beta|^2 \leq t$$

- Cuando $\alpha = 0 \Rightarrow$ LASSO. Cuando $\alpha = 1 \Rightarrow$ Ridge.
- Hereda la **sparsidad** del LASSO y la **estabilidad** del Ridge.
- Está bien definido también cuando $p > n$.
- La versión *corregida* (*elastic net*) re-escala los coeficientes por $(1 + \lambda_2)$ para evitar *double shrinkage*.

Elastic Net = pone las dos multas a la vez.

- λ : qué tan grande es la multa total. Si $\lambda = 0$, volvés a OLS. Si $\lambda \rightarrow \infty$, todos los coeficientes se aplastan a cero.
- α : la mezcla entre las dos multas. $\alpha = 1 \rightarrow$ puro LASSO. $\alpha = 0 \rightarrow$ puro Ridge. $\alpha = 0,5 \rightarrow$ mitad y mitad.

Teorema 1 (informal)

Si dos predictores x_i y x_j están altamente correlacionados ($\rho \rightarrow 1$), entonces los coeficientes del Elastic Net cumplen:

$$|\hat{\beta}_i(\lambda_1, \lambda_2) - \hat{\beta}_j(\lambda_1, \lambda_2)| \leq \frac{1}{\lambda_2} \sqrt{2(1 - \rho)} \rightarrow 0.$$

- Variables muy correlacionadas reciben coeficientes **parecidos** (entran o salen *juntas* del modelo).
- El LASSO **no tiene** esta propiedad: con $\rho \approx 1$ elige una arbitrariamente.
- Ejemplo: en microarrays, “genes que actúan juntos” deben aparecer juntos en el modelo.

Aplicación 1: Cáncer de próstata

Datos clásicos de Stamey et al. (1989).

- **n**: 67 training + 30 test; **p**: 8 predictores clínicos (lcavol, lweight, age, lbph, svi, lcp, gleason, pgg45).
- **Y**: log(PSA) (prostate-specific antigen).
- Selección de hiperparámetros por CV 10-fold.

Método	Test MSE (SE)	Vars. seleccionadas
OLS	0,586 (0,184)	8 (todas)
Ridge	0,566 (0,188)	8 (todas)
LASSO	0,499 (0,161)	5
Naïve Elastic Net	0,566 (0,188)	8 (todas)
Elastic Net	0,381 (0,105)	5

⇒ Elastic Net: **24 % menor error** de predicción que LASSO, manteniendo modelo parsimonioso.

Aplicación 2: Clasificación de leucemia (microarray)

- **Datos:** Golub et al. (1999). **7.129 genes**, **72 pacientes** (38 training, 34 test).
- Y binaria: ALL (leucemia linfoblástica aguda) vs. AML (leucemia mieloide aguda).
- Caso extremo $p \gg n$.

Método	CV error	Test error	# genes
Golub (1999)	3/38	4/34	50
SVM + recursive feature elim.	2/38	1/34	31
Logística penalizada + RFE	2/38	1/34	26
Nearest shrunken centroids	2/38	2/34	21
Elastic Net	3/38	0/34	45

- Elastic Net selecciona **45 genes** – imposible para LASSO, que se topa con el límite $n = 38$.
- Logra **0 errores** en el test set.

Aplicación 3: Estudio de simulación

- 4 escenarios con distintas estructuras de correlación entre predictores; 50 réplicas cada uno.

Método	Ej. 1	Ej. 2	Ej. 3	Ej. 4
LASSO	3,06	3,87	65,0	46,6
Elastic Net	2,51	3,16	56,6	34,5
Ridge	4,49	2,84	39,5	64,5
Naïve EN	5,70	2,73	41,0	45,9

MSE mediano (sobre 50 réplicas).

- Reducción del error de predicción del EN frente al LASSO: **18 %, 18 %, 13 % y 27 %**.
- Conclusión: **cuando hay colinealidad, EN domina al LASSO**.

Resumen: tres papers, tres mensajes

Paper	Método estrella	Mensaje
Edo, Oubiña & Svarc (2024)	LASSO-logit	Permite interpretar qué hogares están en riesgo de violencia infantil con 643 variables; rendimiento comparable a Random Forest.
Bajari et al. (2015)	RF (y combinación)	Frente a la estimación clásica de demanda, los métodos de ML mejoran la predicción; ninguno domina a todos .
Zou & Hastie (2005)	Elastic Net	Combina sparsidad (LASSO) y agrupamiento (Ridge); imprescindible cuando $p \gg n$ o hay variables correlacionadas.

¿Cuándo usar cuál?

Reglas prácticas

- **Ridge**: cuando todos los predictores aportan algo y hay multicolinealidad; no querés excluir variables.
- **LASSO**: cuando esperás que muchos coeficientes *verdaderos* sean cero; querés interpretabilidad.
- **Elastic Net**: cuando $p \gg n$, o hay grupos de variables correlacionadas, o no estás seguro entre las dos anteriores.
- En todos los casos: **estandarizar** los predictores, elegir λ (y α) por **cross-validation**, y reportar el error **fuera de muestra**.

- Bajari, P., Nekipelov, D., Ryan, S. P., & Yang, M. (2015). Machine learning methods for demand estimation. *American Economic Review: Papers & Proceedings*, 105(5), 481–485.
- Edo, M., Oubiña, V., & Svarc, M. (2024). Machine learning and public policy: Early detection of physical violence against children. *Children and Youth Services Review*, 166, 107932.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: with applications in Python* (Cap. 6.1–6.2). Springer.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society B*, 67(2), 301–320.