

Reducción de Dimensionalidad y Modelos No Lineales

Tutorial 10 – PCR, PLS, polinomios, splines y regresión local

Luciana Azul Ramirez

E337 – Big Data para Economistas
Universidad de San Andrés

Otoño 2026

Primera parte: intuición y comparación de métodos

- ➊ **Métodos basados en reducción de dimensionalidad:** PCR y PLS.
- ➋ **Métodos no lineales:** regresión polinómica, *step functions*, splines y regresión local.

Segunda parte: papers aplicados

- ➊ **Diamond (2016, AER)** – PCA sobre amenities urbanas.
- ➋ **Lee, Moretti & Butler (2004, QJE)** – regresión polinómica local en un RDD.

Aplicación adicional (cierre): Bertrand, Kamenica & Pan (2015, QJE) – splines.

Tercera parte: notebook en Python

`Tut10_PCR_PLS_Modelos_no_lineales.ipynb` con `scikit-learn`, `statsmodels` y `scipy`.

Parte I

Métodos basados en reducción de dimensionalidad: PCR y PLS

¿Por qué reducir la dimensionalidad?

- Cuando tenemos **muchos predictores** (p grande) o **altamente correlacionados**, OLS:
 - tiene varianza alta (overfitting),
 - es inestable (pequeños cambios en los datos $\Rightarrow$ grandes cambios en $\hat{\beta}$),
 - no está definido si $p > n$.
- **En el Tutorial 9** vimos una respuesta: *penalizar* los coeficientes (LASSO, Ridge, Elastic Net).
- **Hoy** vemos otra estrategia: **transformar** los predictores en un número *más chico* de variables nuevas $-(M)$ de CL- y correr OLS sobre esas.

Idea común a PCR y PLS

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j, \quad m = 1, \dots, M, \quad M \ll p$$

Después: $Y = \theta_0 + \theta_1 Z_1 + \dots + \theta_M Z_M + \varepsilon.$

Regresión por Componentes Principales (PCR)

Dos pasos:

- 1 **PCA sobre X** : encuentra direcciones $\phi_1, \phi_2, \dots$ que **maximizan la varianza de X** .
 - Z_1 : combinación lineal de los X_j con *máxima* varianza.
 - Z_2 : ortogonal a Z_1 , con máxima varianza entre las que quedan.
 - Y así sucesivamente.
- 2 **OLS**: regresar Y sobre $Z_1, \dots, Z_M$ (no sobre los X originales).

Intuición

Si las direcciones de mayor varianza en X son las que más se relacionan con Y , PCR reduce dimensionalidad sin perder mucho poder predictivo.

- Hiperparámetro: el número M de componentes $\Rightarrow$ se elige por **cross-validation**.
- **Estandarizar X** es *imprescindible* (PCA es sensible a la escala).

- **PCA es no supervisado:** solo mira X , ignora Y .
 - *No hay ninguna garantía* de que las direcciones de mayor varianza en X sean las más útiles para predecir Y .
 - Podemos descartar una dirección de baja varianza en X que sin embargo está muy correlacionada con Y .
- **Pérdida de interpretabilidad:** cada Z_m es una mezcla de los p predictores originales $\Rightarrow$ los coeficientes θ_m no dicen nada sobre el efecto de un X_j específico.
- No hace **selección** de variables (todos los X_j entran en cada componente).

Comparación rápida

PCR se parece más a **Ridge** que a LASSO: encoge en direcciones de baja varianza, pero no produce ceros.

Partial Least Squares (PLS)

La gran diferencia con PCR: PLS es *supervisado*, usa información de Y para construir las componentes.

- **Primera componente:** dirección que maximiza la **covarianza** con Y :

$$Z_1 = \sum_{j=1}^p \phi_{j1} X_j, \quad \phi_{j1} \propto \text{Cor}(X_j, Y).$$

Variables más correlacionadas con Y reciben *más peso*.

- **Componentes siguientes:** tras ortogonalizar X respecto de Z_1 , repetir el procedimiento.
- Resultado: $Z_1, \dots, Z_M$ son combinaciones lineales que tratan de *explicar* Y y a la vez *capturar la variación de* X .
- Mismo paso final que en PCR: $Y = \theta_0 + \theta_1 Z_1 + \dots + \theta_M Z_M + \varepsilon$.
- Mismo hiperparámetro (M), elegido por **cross-validation**.
- También requiere **estandarizar** X .

PCR vs. PLS: una tabla

	PCR	PLS
¿Usa Y al construir componentes?	No (<i>no supervisado</i>)	Sí (<i>supervisado</i>)
¿Qué maximiza la 1. ^a comp.?	$\text{Var}(Z_1)$	$\text{Cov}(Z_1, Y)$
Riesgo principal	Elegir componentes irrelevantes para Y	Sobreajustar a Y con ruido
Hiperparámetro	M (CV)	M (CV)
Performance típica	Similar a Ridge	Suele rendir parecido a PCR en la práctica

- Ambos son **lineales** en las componentes $\Rightarrow$ no resuelven no-linealidades.
- Ambos **requieren estandarizar** X antes de aplicarlos.
- En empíricos: PLS suele ganarle poco a PCR. La principal ventaja conceptual es el carácter supervisado.

Parte II

Modelos no lineales: polinomios, step functions, splines, regresión local

¿Por qué relajar el supuesto de linealidad?

- OLS asume que $E[Y | X] = X'\beta$ es **lineal** en X .
- En muchos problemas reales esto es falso:
 - Salarios crecen con la edad y luego *caen* (perfil edad-salario tipo Mincer).
 - Demanda no es lineal en el precio.
 - Relación entre años de educación y ingresos tiene retornos no constantes.
- Forzar linealidad $\Rightarrow$ **sesgo** de especificación y mal poder predictivo.
- **Idea**: ampliar la familia de modelos manteniendo la simpleza de OLS, transformando X con bases más ricas.

Algunas estrategias

1. **Polinomios** (globales) $\rightarrow$ 2. **Step functions** (constantes a trozos) $\rightarrow$ 3. **Splines** (polinomios a trozos, suaves) $\rightarrow$ 4. **Regresión local** (vecindario móvil).

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_d X^d + \varepsilon$$

- Sigue siendo *lineal en los parámetros* $\Rightarrow$ se estima por OLS.
- Captura no linealidades **globales**.
- Hiperparámetro: el grado d , elegido por **cross-validation**.

Limitaciones

- Con d grande, el ajuste **oscila** y se vuelve inestable en las colas (*fenómeno de Runge*).
- Un único polinomio impone *la misma forma* en todo el rango de X : poco flexible en zonas con pocos datos.
- En la práctica, rara vez se usan grados mayores a 3 o 4.

Step functions (constantes a trozos)

- Cortamos el soporte de X en K **intervalos** (por cuantiles, por ejemplo) y estimamos un nivel constante de Y en cada uno:

$$Y = \beta_0 + \sum_{k=1}^{K-1} \beta_k 1\{c_k \leq X < c_{k+1}\} + \varepsilon.$$

- Equivale a meter **dummies** (efectos fijos por bin).
- Útil cuando *hay cortes naturales* (edades de jubilación, tramos impositivos, calificación crediticia).

Limitaciones

- La función es **discontinua** en los cortes: saltos que rara vez existen en la realidad.
- Pierde toda la información sobre la *tendencia* dentro de cada bin.

Splines: polinomios a trozos con costuras suaves

- Combinamos lo mejor de polinomios y step functions:
 - Cortamos X en regiones con **nudos** (*knots*) $\xi_1, \xi_2, \dots$
 - Ajustamos un **polinomio** (típicamente cúbico) *en cada región*.
 - Imponemos **continuidad** en el nudo: mismo valor y misma primera y segunda derivada $\Rightarrow$ curva suave.
- Spline cúbico = la opción estándar (suave a simple vista).
- **Natural splines**: además fuerzan linealidad fuera del rango de los nudos $\Rightarrow$ mejor comportamiento en las colas.

Hiperparámetros y grados de libertad

- Cantidad y ubicación de los **nudos** (típicamente por cuantiles), elegidos por **cross-validation**.
- Cada *restricción de continuidad* en un nudo **libera un grado de libertad**: un spline cúbico con $d = 8$ pasa a $d = 7$ tras imponer continuidad, $d = 6$ tras imponer continuidad de la primera derivada, etc.
- Alternativa: **smoothing splines**, con término de penalización (lógica similar a Ridge).

Regresión local (LOWESS / LOESS)

- En lugar de imponer una forma funcional global, **ajustamos una regresión en una ventana móvil** alrededor de cada x_0 .
- Para predecir $\hat{f}(x_0)$:
 - 1 Tomar el subconjunto de observaciones *más cercanas* a x_0 (la “vecindad”).
 - 2 Asignarles pesos según una función de **kernel** (tricúbico, gaussiano, ...): más peso, más cerca.
 - 3 Estimar una regresión local ponderada (lineal o cuadrática) y leer $\hat{f}(x_0)$ ahí.
- Hiperparámetro principal: el **ancho de la ventana** (“*span*” o *bandwidth*).
 - Pequeño $\Rightarrow$ curva muy local, baja sesgo / alta varianza.
 - Grande $\Rightarrow$ curva muy suave, alto sesgo / baja varianza.

Cuándo sirve (y cuándo no)

Ideal para **exploración visual** y cuando no querés imponer forma funcional.

- **Maldición de la dimensionalidad**: con más de 3–4 predictores, los “vecinos” se vuelven escasos y la performance cae bruscamente.
- Caro computacionalmente con n grande.

Resumen: ¿cuándo usar cuál?

Método	Idea	Cuándo lo elegimos
Polinómica	Una sola curva $\beta_0 + \beta_1 X + \dots + \beta_d X^d$	No-linealidad simple y <i>global</i> ; pocos datos.
Step function	Bins con nivel constante	Existen <i>cortes naturales</i> ; queremos algo súper interpretable.
Splines	Polinomios a trozos suaves	Necesitamos flexibilidad <i>local</i> y una curva suave.
Regresión local	Ventana móvil ponderada	Visualización; no queremos imponer una forma; n moderado.

- En todos: **cross-validation** para elegir hiperparámetros (grado, número de bins, nudos, bandwidth).
- Trade-off central: **sesgo vs. varianza**.

Parte III

Dos papers de la bibliografía obligatoria

Primer Trabajo

Rebecca Diamond (2016)

*The Determinants and Welfare Implications of US Workers' Diverging Location Choices
by Skill: 1980–2000*

American Economic Review, 106(3), 479–524.

- **Hecho a explicar:** entre 1980 y 2000 los trabajadores con título universitario se concentraron en ciudades caras (Boston, San Francisco), mientras los menos educados se fueron a ciudades baratas.
- ¿Por qué? Los *college* aceptan salarios reales más bajos a cambio de mejores **amenities** urbanas (escuelas, baja criminalidad, oferta cultural. . .).
- **Pregunta:** ¿cuánto del aumento en desigualdad de bienestar entre skills se debe a divergencia en **amenities**, y no solo a salarios?
- **Por qué importa para nuestro tema:** la autora mide “amenities” con *muchísimas* variables $\Rightarrow$ caso típico de **reducción de dimensionalidad**.

- Datos a nivel **Metropolitan Statistical Area** (MSA) en 1980, 1990 y 2000.
- *Census* + *American Community Survey* + datos administrativos.
- Decenas de variables que describen **calidad urbana**:
 - Crimen (violento, contra la propiedad)
 - Polución (medidas EPA)
 - Educación (calidad de escuelas, ratios alumno-docente)
 - Salud, transporte, oferta de retail y restaurantes...
- **Problema**: meter todas estas variables como regresores rompe identificación (multicolinealidad masiva, sobreparametrización).

Solución

Resumir todo el menú de amenities en **unos pocos índices** con análisis de componentes principales.

¿Cómo usa PCA?

- Junta las variables de amenities en **4 grandes grupos temáticos** y aplica PCA dentro de cada uno:
 - ① **Calidad de escuelas** (ratios, gasto por alumno, test scores).
 - ② **Seguridad / crimen** (tasas de delitos violentos y contra la propiedad).
 - ③ **Polución y ambiente** (medidas EPA).
 - ④ **Retail / vida urbana** (restaurantes, comercios, oferta cultural).
- Para cada grupo: se queda con la **primera componente principal** (la que captura la mayor parte de la varianza).
- Resultado: **4 índices** de amenities por MSA $\Rightarrow$ los usa como variables explicativas en un modelo estructural de elección de ciudad.

Por qué tiene sentido

Las distintas medidas de “calidad de escuelas” están *altamente correlacionadas* entre sí; un único índice resume la información sin perder mucho.

Resultado y mensaje metodológico

- Con los índices de amenities, Diamond estima:
 - Cómo eligen ciudad los trabajadores de cada nivel educativo.
 - Cuánto vale en términos monetarios cada amenity para cada grupo.
- **Hallazgo principal:** la divergencia geográfica por skills **aumentó la desigualdad de bienestar** *aún más* que la divergencia salarial; las amenities explican una porción importante.

Mensaje metodológico

Cuando el constructo de interés (“calidad urbana”) se mide con **muchas variables correlacionadas**, PCA permite:

- evitar multicolinealidad,
- retener la información esencial,
- interpretar el coeficiente sobre el índice como “el efecto del concepto subyacente”.

Segundo Trabajo

Lee, Moretti & Butler (2004)

Do Voters Affect or Elect Policies? Evidence from the U.S. House

Quarterly Journal of Economics, 119(3), 807–859.

- Dos visiones de la política democrática:
 - “**Voters affect**”: los candidatos compiten por el votante mediano y *convergen* en políticas.
 - “**Voters elect**”: los candidatos son tipos comprometidos con su plataforma; el votante *elige un tipo*, no condiciona a quien gana a moderarse.
- **Pregunta**: ¿qué pasa con el voto real (roll call) de un legislador cuando su partido gana por estrechísima diferencia vs. pierde por estrechísima diferencia?
- **Por qué importa para nuestro tema**: identifican efectos causales con un **regression discontinuity design**, donde la forma funcional cerca del *cutoff* se estima con **polinomios** y **regresión local**.

Identificación: regression discontinuity

- Unidad: distrito $\times$ elección a la Cámara de Representantes de EE.UU.
- Variable *running*: **margen de victoria** demócrata, v .
- **Tratamiento**: ganar la elección ($v > 0$). Esto se decide *discontinuuamente* en $v = 0$.
- Outcome: **ADA score** del legislador electo (índice de liberalismo en roll-call votes).
- Bajo el supuesto de continuidad de potenciales en $v = 0$, el salto en el outcome *en* el cutoff identifica el efecto de tener un representante demócrata.

El rol de los métodos no lineales

Hay que estimar $E[Y \mid v]$ **a cada lado del cutoff** de forma flexible. Las opciones del paper son justamente las que vimos hoy: polinomios y regresión local.

- Modelo principal: **regresión polinómica** en el margen v a cada lado del cutoff,

$$Y_i = \alpha + \tau D_i + \sum_{k=1}^d \beta_k v_i^k + \sum_{k=1}^d \gamma_k v_i^k D_i + \varepsilon_i,$$

con $D_i = 1\{v_i > 0\}$. El parámetro de interés es τ : el salto en el cutoff.

- Reportan estimaciones con **distintos grados** d (cuadrática, cúbica, cuártica) como chequeo de robustez.
- Adicionalmente: **regresión local lineal** (kernel) restringiendo a observaciones cercanas a $v = 0$.
- Si el efecto es robusto a la forma funcional y al ancho de ventana, gana credibilidad.

Resultado y conexión con el método

- En el cutoff: enorme salto en el ADA score $\Rightarrow$ ganar por un voto cambia mucho cómo vota el representante.
- **Mismo legislador** antes y después del cutoff vota *casi idéntico*.
- Conclusión: “**voters elect**”, no *affect*. Los candidatos están *comprometidos* con su plataforma.

¿Qué aporta el método no lineal?

- Sin polinomios o regresión local no se puede estimar bien la curva $E[Y | v]$ cerca del cutoff.
- La elección entre lineal local, polinomio cuadrático o spline **cambia las estimaciones** en problemas más sutiles $\Rightarrow$ por eso se reporta varias.
- Hoy la práctica estándar es *regresión local lineal* con **bandwidth óptimo** (Imbens-Kalyanaraman, Calonico-Cattaneo-Titiunik).

Gender Identity and Relative Income within Households

Quarterly Journal of Economics, 130(2), 571–614.

¿Cómo aparecen los splines en este paper?

- **Pregunta:** ¿hay una discontinuidad en la distribución del cociente *ingreso de la mujer / ingreso del hogar* justo en 0,5?
- **Método:** *suavizan* un histograma de la variable con técnicas no paramétricas (splines / kernels) y comparan con un contrafáctico continuo (test estilo McCrary 2008).
- **Resultado:** salto visible en la densidad en 0,5 $\Rightarrow$ “masa faltante” en parejas donde la mujer gana ligeramente más que el marido. Coherente con una norma de género que penaliza esa configuración.

Conexión metodológica: los splines no sirven solo para estimar $E[Y | X]$; también permiten *suavizar* una distribución y detectar discontinuidades que un ajuste paramétrico ocultaría.

Paper	Método estrella	Mensaje
Diamond (2016)	PCA / PCR	Reducir un menú de amenities urbanas a 4 índices permite medir el aporte de calidad urbana a la desigualdad de bienestar.
Lee, Moretti & Butler (2004)	Polinomios + reg. local	En un RDD, la forma funcional flexible cerca del cutoff es clave; “los votantes eligen tipos, no moderan candidatos”.

Cuándo elegir cada familia (regla práctica)

- **Reducción de dimensionalidad (PCR / PLS):** cuando X tiene muchas variables correlacionadas *que miden lo mismo*. Diamond: amenities.
- **Modelos no lineales:** cuando el supuesto de linealidad es claramente falso o la forma funcional misma es objeto de interés.
 - *Polinomios / regresión local:* estimar $E[Y | X]$ flexiblemente (Lee et al.).
 - *Splines:* relaciones suaves con cambios locales.
- En todos los casos: **cross-validation** para hiperparámetros, **estandarizar** cuando corresponda, evaluar **fuera de muestra**.

Ahora vamos a ver cómo se implementan estos métodos en Python.

Notebook: `Tut10_PCR_PLS_Modelos_no_lineales.ipynb`

Datos:

- Hitters (ISLP) para PCR y PLS: predecir Salary de jugadores de la MLB con ~ 20 estadísticas de desempeño.
- Wage (ISLP) para métodos no lineales: relación age-wage en el Mid-Atlantic.

Herramientas que vamos a usar:

- `sklearn.decomposition.PCA` + `LinearRegression` (vía Pipeline) para PCR.
- `sklearn.cross_decomposition.PLSRegression` para PLS.
- `sklearn.preprocessing.PolynomialFeatures` + `statsmodels.OLS` para polinomios.
- `pd.qcut` + dummies para step functions.
- `scipy.interpolate.BSpline` para splines.
- `statsmodels.nonparametric.smoothers_lowess` para regresión local.

- Bertrand, M., Kamenica, E., & Pan, J. (2015). Gender identity and relative income within households. *Quarterly Journal of Economics*, 130(2), 571–614.
- Diamond, R. (2016). The determinants and welfare implications of US workers' diverging location choices by skill: 1980–2000. *American Economic Review*, 106(3), 479–524.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: with applications in Python*. Cap. 6.3 y 7.1–7.6. Springer.
- Friedman, J., Hastie, T., & Tibshirani, R. (2001). *The elements of statistical learning*. Cap. 3.6.2, 5.1, 5.2. Springer.
- Lee, D. S., Moretti, E., & Butler, M. J. (2004). Do voters affect or elect policies? Evidence from the U.S. House. *Quarterly Journal of Economics*, 119(3), 807–859.