

Análisis de Supervivencia: modelar el *tiempo hasta un evento*

Tutorial 14 – Cuando el dato no es *cuánto*, sino *cuándo*

Luciana Azul Ramirez

E337 – Big Data para Economistas
Universidad de San Andrés

Otoño 2026

Los conceptos del día (y su orden en el notebook)

- 1 **La censura**: por qué OLS no sirve con datos de duración.
- 2 $S(t)$ y el ***hazard***: los dos objetos centrales.
- 3 **Kaplan-Meier**: estimar y *leer* la curva de supervivencia.
- 4 **Log-rank**: comparar dos grupos.
- 5 **Modelo de Cox**: regresión con covariables y *hazard ratios*.
- 6 **Una lección** (datos Publication) y **una simulación** para cerrar.

Todo se ve en Python

Notebook Tut14_Supervivencia.ipynb con el paquete lifelines.

Un *outcome* distinto: tiempo hasta un evento

- El curso modeló *outcomes* **continuos** (precio, ingreso) y **categoricos** (default sí/no). Hoy: **el tiempo que pasa hasta que ocurre un evento**.
- Ejemplos de economía: duración del **desempleo**, **supervivencia de firmas**, **default** de crédito, *churn* de clientes.

Por qué no alcanza con OLS sobre el tiempo?

Porque cuando termina el estudio **muchas observaciones todavía no vieron el evento**. Sabemos que “lleva 20 meses desempleado y sigue”, pero no *cuándo* conseguirá trabajo: solo que es ≥ 20 . Eso es **censura**.

- Tirar las censuradas *subestima* la duración (quedan solo los eventos rápidos); imputarles el máximo también sesga.

Censura, y dos parientes que se confunden

Concepto	Qué pasa con la observación	Es sesgo de selección?
<i>Trimming</i>	La vi entera y decido sacarla	No (decisión del investigador)
<i>Truncamiento</i>	Nunca entró; ni sé que existe	Sí : su ausencia depende de Y
<i>Censura</i>	Está, pero la veo a medias (un límite)	No: aporta información parcial

La idea para fijar

Trimming: “la vi y la tiro”. *Truncamiento*: “no la vi, ni sé que existe”. *Censura*: “la veo a medias”.
El análisis de supervivencia existe para usar bien la **censura**.

Los dos objetos centrales: $S(t)$ y $h(t)$

Función de supervivencia

$$S(t) = \Pr(T > t)$$

Probabilidad de “seguir vivo” (no haber tenido el evento) más allá de t . Si el evento es “cerrar la empresa”, $S(5)$ es la probabilidad de seguir abierta a los 5 años.

Función de riesgo (*hazard*)

Tasa instantánea del evento en t , **dado que se sobrevivió hasta t** . Si $h(t)$ es alto, “el evento está por pasar ya”.

- Codificación: status= 1 (evento observado), status= 0 (censurado).
- **Kaplan-Meier** estima $S(t)$; el **modelo de Cox** modela $h(t)$.

Kaplan-Meier: la curva escalonada

Idea: estimar $S(t)$ *sin suponer ninguna forma funcional*. Se arranca con todos vivos (curva en 1) y se baja un escalón cada vez que ocurre un evento.

El rol de cada observación

- Una **muerte** hace *bajar* la curva (escalón vertical).
 - Un **censurado** *no* baja la curva (a lo sumo deja una crucecita en el tramo plano)...
 - ... pero al irse **achica la cantidad en riesgo**, así que *la próxima muerte cae más* (escalón más profundo).
-
- Así no se descarta al censurado (sería injusto) ni se lo trata como muerto (sería falso): se lo usa **hasta donde se lo vio**.

Para qué sirve la curva de Kaplan-Meier?

- **Leer probabilidades en el tiempo:** “a los 12 meses, qué fracción sigue viva / desempleada / sin quebrar?”. Es una proporción *ajustada por censura* (algo que un promedio simple no puede dar).
- **Mediana de duración:** el tiempo donde la curva cruza 0,5. “La mitad de los desempleados consigue trabajo antes de los 5 meses.”
- **Mirar la forma:** cae rápido al principio y se aplana? hay un “precipicio” en algún momento?

En una frase

Es lo *descriptivo*: dice **qué** pasa con la duración, antes de preguntarnos **por qué**. Todavía no compara grupos ni controla por nada.

Comparar grupos: el test de log-rank

- Se dibuja **una curva de Kaplan-Meier por grupo** (tratamiento vs. control, etc.). La curva más arriba “dura” más.
- Pero la separación visual puede ser ruido: el **log-rank** decide si la diferencia es real.

Qué hace, intuitivamente

Recorre el tiempo y, en cada evento, compara los eventos *esperados* en cada grupo (según cuántos quedaban en riesgo) contra los *observados*. Si esas sorpresas se acumulan, las curvas son distintas.

- Es el análogo, en supervivencia, de un **test de diferencia de medias**. H_0 : las dos curvas son iguales.
- **Limitación**: solo compara grupos; no deja controlar por covariables (ej. sexo, diagnóstico) ni usar regresores continuos (ej. edad, tamaño del tumor) → por eso viene Cox.

El modelo de Cox: la regresión de la supervivencia

La idea: no modelar el tiempo directamente, sino el **riesgo** (*hazard*), dejando que cada covariable lo *multiplique* hacia arriba o hacia abajo.

Riesgos proporcionales

$$h_i(t) = h_0(t) \exp(\beta_1 x_{i1} + \cdots + \beta_p x_{ip})$$

$h_0(t)$ es el riesgo base, común a todos y **sin especificar** (“semiparamétrico”); las covariables solo lo corren. No hay intercepto: queda absorbido en h_0 .

- Con un único regresor binario, **Cox reproduce exactamente el log-rank**: una generaliza a la otra.

Hazard ratio

e^{β_j} es la **razón de riesgos**: cuánto *multiplica* el riesgo un cambio en x_j .

$\beta_j > 0 \Rightarrow$ más riesgo $\Rightarrow$ el evento llega **antes** $\Rightarrow$ menos supervivencia.

- **Ejemplo del notebook** (datos BrainCancer): el tumor más agresivo (HG glioma) tiene un riesgo $\approx e^{2,15} \approx 8,6$ veces el de un **meningioma** (la categoría de referencia del modelo es HG glioma), manteniendo todo lo demás constante.
- Mejor estado funcional del paciente (*Karnofsky*) $\rightarrow$ coeficiente negativo $\rightarrow$ menos riesgo $\rightarrow$ más supervivencia.
- Las **curvas de supervivencia predichas** por diagnóstico hacen visible ese resultado: el agresivo se desploma; los benignos se sostienen.

En el **notebook** (datos Publication): se publican antes los estudios con *resultado positivo*?

El experimento

- Cox con **solo** esa variable → *no* significativa ($p \approx 0,36$).
- Cox **controlando** por las demás covariables → **muy** significativa ($p \approx 0,001$).
- Había **confusores** (el “impacto” del estudio) que enmascaraban el efecto.
- Es el mismo **sesgo de variable omitida** de OLS, ahora en un modelo de duración: las reglas econométricas que ya saben **siguen valiendo**.

Una simulación para cerrar: el método funciona?

- Con datos reales nunca conocemos “la verdad”, así que no podemos saber si el modelo acierta.
- **Solución:** fabricar los datos nosotros. En el notebook simulamos 2000 llamadas a un *call center* (evento = ser atendido; tiempo = espera; censura = el cliente cuelga antes).

Simulación

Definimos a mano los efectos verdaderos, generamos los datos y le pasamos todo a *Cox sin contarle las reglas*. Al comparar, los coeficientes estimados **coinciden bastante bien** con los verdaderos... a pesar de la censura.

- Construye confianza: el método solo **recupera la realidad** que generó los datos.

Resumen: cuándo usar cuál?

	Para qué sirve?	Limitación
Kaplan-Meier	Estimar y <i>leer</i> $S(t)$, mediana de duración	Solo descriptivo; sin covariables
Log-rank	Comparar dos (o más) grupos	No controla por nada
Cox PH	Regresión con covariables; <i>hazard ratios</i>	Supone riesgos proporcionales

- Flujo típico: **KM** (mirar) → **log-rank** (difieren grupos?) → **Cox** (qué empuja el riesgo, controlando por todo?).

Notebook: Tut14_Supervivencia.ipynb (paquete lifelines)

Datos:

- BrainCancer (ISLP): supervivencia de pacientes; censura real.
- Publication (ISLP): tiempo hasta publicación; lección de variable omitida.
- *Call Center* (simulado con `ISLP.survival.sim_time`): recuperar parámetros.

Herramientas:

- KaplanMeierFitter para estimar y graficar $S(t)$.
- `logrank_test` y `multivariate_logrank_test`.
- `CoxPHFitter` (`.fit`, `.summary`, `predict_survival_function`).

- Cox, D. R. (1972). Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B*, 34(2), 187–202.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Cap. 11: Survival Analysis and Censored Data. Springer.
- Kaplan, E. L., & Meier, P. (1958). Nonparametric Estimation from Incomplete Observations. *Journal of the American Statistical Association*, 53(282), 457–481.
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*, 2.^a ed., Cap. 22: Duration Analysis. MIT Press.